

Pengantar Proyek Sain Data

KONSEP DAN IMPLEMENTASI DATA SCIENCE UNTUK ANALISA BISNIS

Mulaab Mulyo

PRODI TEKNIK INFORMATIKA
UNIVERSITAS TRUNOJOYO MADURA

Kelas A

- <https://forms.gle/Qv4DEFLYpA8znqGa7>



Kelas B

- <https://forms.gle/kW4UmeuERNqUkPK56>



Ketentuan Kuliah PSD

- **Masuk tepat waktu** : (terlambat dilarang masuk)
 - 07.00-9.30 : Kelas
 - 09.40-12.00 : Kelas
- Membuat Repositori github.username/PSD
- Membawa laptop (**tidak bawa laptop dilarang masuk**)
- Tidak hadir ≥ 4 (**Nilai D**))
- Ketua Kelas :

A	B
Nama : Habibah NIM : 240411100169 NoWa :085847730295	Nama : NIM : No Wa :

Kelas B

- <https://forms.gle/kW4UmeuERNqUkPK56>

Rencana Pembelajaran Semester

Dokumen RPS Proyek Sains Data [disini](#)

Capaian Pembelajaran Mata Kuliah

- Mampu menjelaskan tahapan atau siklus proyek sains data, output dan kendala yang dihadapi pada setiap fase atau stage
- Menerapkan pendekatan matematika dan statistika untuk mendeskripsikan data yang diterima dari pihak pemberi proyek, termasuk memeriksa kejanggalan atau kekurangan dari data tersebut
- Menerapkan teknik visualisasi untuk mendeskripsikan data dengan lebih jelas dan memudahkan analisis dan pembersihan data
- Menggunakan bahasa pemrograman, framework, dan library tertentu untuk analisis data, pembuatan model, dan deploy perangkat lunak sains data

Capaian Pembelajaran Mata Kuliah

- Melakukan imputasi dan normalisasi data sehingga proses analisis nantinya dapat dilaksanakan secara tepat dan lebih mudah
- Memilih dan menerapkan teknik machine learning terbaik menggunakan teknologi dan perangkat yang tepat sehingga diperoleh model yang tepat, baik untuk prediksi (klasifikasi atau regresi), segmentasi pelanggan, clustering, atau tujuan lain

- Menguji dan mengevaluasi kinerja model machine learning yang dihasilkan menggunakan metrik yang diakui secara internasional dan memperbaiki tahapan sebelumnya untuk memperoleh kinerja yang lebih baik
- Mendeploy hasil proyek sains data sesuai dengan teknologi yang digunakan
- Mampu membuat dokumen teknis pengembangan perangkat lunak sains data (untuk tim pengembang) dan dokumen panduan penggunaan (untuk pengguna)

- Pertemuan I
 - Pengantar Sains Data
 - Kebutuhan Sains Data •
 - Tahapan/Siklus hidup Sains Data
- Pertemuan II
 - Business Problem Understanding
 - Exploratory Data Analysis
 - Penggunaan tools statistik untuk menganalisa data (Power BI)
 - Data Kaggle sebagai data acuan
- Pertemuan III
 - Data Engineering
 - Mapping Data o
 - Integrasi Data o
 - Transformasi Data

- Pertemuan IV (Data Preparation)
 - Cleaning Data
 - Normalisasi Data
 - Balancing Data
 - Missing Value
 - Outlier Detection
 - Pertemuan IV
- Pertemuan V (Data Preparation)
 - Extraction Feature
 - Selection Feature

- Pertemuan VI (Modelling dan evaluasi)
 - Supervise Learning
 - Unsupervise Learning
 - Evaluasi
- Pertemuan VI I(Deployment)
 - Framework Web
 - Containerisasi

Pengertian dan Manfaat



Mempelajari dan menganalisis data menggunakan alat dan teknik modern untuk menemukan pola yang tidak terlihat dan informasi untuk membuat keputusan bisnis.



Pada era digital dan big data saat sangat penting karena melimpahnya data yang tersedia. (3V)



Memberikan informasi yang dapat menentukan keputusan penting dalam berbagai sektor industri (smarter decisions)

Manfaat Sains Data (Data Mining)

Membantu dalam membuat keputusan bisnis

Memahami pelanggan dan pasar

Memperbaiki kualitas produk

Meningkatkan layanan

Memperbaiki proses bisnis

Membuat nilai tambah (revenue) dari data

Membantu dalam membuat keputusan bisnis

- membantu perusahaan mencapai tujuannya
- Membantu memenuhi kepuasan pengguna
- Keputusan berdasarkan data (key business questions)

Credit Risk Modeling


Credit Risk Modeling

- Pemodelan risiko kredit adalah proses memperkirakan probabilitas bahwa peminjam akan gagal membayar pinjaman mereka
 - Siapa yang ditolak dan siapa yang diterima
 - Berapa besaran pinjaman yang harus di berikan
 - Jangka waktu pengembalian kredit

<https://www.kaggle.com/code/krishnapriya/cr-edit-risk-modelling-catboost-93-5-accuracy>

Memahami pelanggan dan pasar

- Memahami trend permintaan pasar
- Memprediksi kenaikan harga
- Memprediksi penumpang untuk bisnis transportasi
- untuk memahami pelanggan (siapa, dimana dan apa kebutuhannya)
- Untuk analisa market trend trend pelanggan berdasarkan
 - suku bunga bank,
 - GDP, dll




Data Pelanggan

- **Macam data Pelanggan**
 - Personal data yang terkait dengan data diri dan data demography
 - Behavioural data yang terkait dengan transaksi yang telah dilakukan dengan perusahaan. (web log, interaksi e-commerce)
 - Attitudinal data: data yang diperoleh tidak secara langsung dengan bisnis. Data ini terkait dengan respon pelanggan terhadap produk dan layanan perusahaan. Data bisa diperoleh dari survey atau sentimen pada media sosial

Memperbaiki kualitas produk



- Contoh : **Modelkan kuat tekan beton**
 - Kuat tekan merupakan salah satu sifat yang paling penting dari beton.



<https://www.neuraldesigner.com/learning/examples/concrete-properties-assessment#NeuralNetwork>

Meningkatkan layanan

- Pembelajaran mesin memungkinkan kita untuk membangun model yang mengaitkan berbagai variabel terhadap pengobatan pada masing-masing pasien




<https://www.neuraldesigner.com/learning/examples/concrete-properties-assessment#NeuralNetwork>

Meningkatkan layanan

PREDIKSI KEBAKARAN HUTAN

FFMC : indikator potensi tingkat kemudahan penyulutan api menjadi kebakaran

Duff Moisture Code (DMC) : **kode kadar air bahan bakar pada lapisan tanah organik yang tidak padat dengan kedalaman sekitar 7 cm.**



<https://www.neuraldesigner.com/learning/examples/forest-fires#DataSet>

Memperbaiki proses bisnis

gabungan *data mining* dan *process analytics*

- untuk memahami performa dari setiap proses bisnisnya
- Untuk mengetahui apakah terdapat *bottleneck* atau proses yang tidak berjalan efektif dalam keseluruhan proses bisnisnya
- mengetahui hal-hal apa saja yang bisa ditingkatkan dalam proses secara keseluruhan

<http://www.processmining.org/software.html>



<https://www.ibm.com/cloud/learn/process-mining#:~:text=Process%20mining%20applies%20data%20science,and%20other%20areas%20of%20improvement>

Uses Cases

- <https://towardsdatascience.com/introduction-to-process-mining-5f4ce985b7e5>
- <https://www.youtube.com/watch?v=VgQjoAHxsqw>

Kolaborasi Manager Proses Sains Data



- **Business Managers:** adalah orang yang menghubungkan kebutuhan bisnis dan manfaat dari data yang diekstrak.
- **IT manager :** bertanggung jawab untuk menyediakan infrastruktur dan arsitektur terhadap kebutuhan data scientist
- **Data Science Managers :** bertanggung jawab terhadap prosedur atau tahapan proses sains data. Juga melakukan supervisi terhadap team sains data

Tugas Data Scientist

- Menemukan pola dan trend dari dataset untuk dijadikan informasi
- Melakukan pemodelan terhadap dataset
- Memberikan masukan terhadap top management

Karier Sains Data



Data Scientist



Data Analyst



Data Engineers



Business Intelligence Specialist



Data storyteller



Data Scientist

- Profesi seorang yang memerlukan keterampilan membangun algoritma *Machine Learning* yang digunakan untuk memprediksi peristiwa yang akan datang dengan cara:
 - Membangun model klasifikasi
 - Membangun model prediksi/forecasting
- Profesi seseorang untuk membangun sebuah model pola dalam data sehingga dapat memahami karakteristik dari data (model Clustering)



Data Analyst

- Profesi seorang untuk memecahkan sebuah permasalahan dengan cara melakukan analisa data yang berkaitan dengan masalah tersebut.
- Data analis memiliki akses ke data-data yang dibutuhkan untuk ditransformasi dan dilakukan pemodelan.
- Mengolah, mendiskripsikan data dan memvisualisasikan data untuk diambil kesimpulan dan dilakukan visualisasinya.
- Data Analis memerlukan keterampilan teknik visualisasi data, statistik ringkasan dan inferensial, keterampilan presentasi dan komunikasi.



Data Engineers

- bertugas mengumpulkan dan mengelola arsitektur data
- mengembangkan arsitektur dari data warehouse yang telah dianalisa
- Memberikan peta jalan aliran data pada perusahaan.
- Merancang dan mengimplementasikan penyimpanan data
- Merancang dan mengembangkan pemrosesan data
- Merancang dan mengimplementasikan keamanan data
- Memonitoring dan mengoptimalkan penyimpanan data dan pemrosesan data
- Membangun pipeline data



Bussiness Intelegence specialist

- Bertanggung jawab membangun metodologi analisis informasi yang berhubungan dengan bisnis perusahaan
- Membantu perusahaan untuk mencapai tujuan bisnis
- Mengidentifikasi masalah dalam suatu bisnis dan memberikan alternatif solusi dalam suatu bisnis
- Memiliki pengetahuan keuangan dan bisnis
- Wixom & Watson, 2010: **“Business intelligence is an umbrella term that is commonly used to describe the technologies, applications, and processes for gathering, storing, accessing, and analyzing data to help users make better decisions.**



Data storyteller

- Kemampuan untuk mengkomunikasikan pengetahuan secara efektif dari kumpulan data menggunakan narasi dan visualisasi. Ini dapat digunakan memberi masukan dan inspirasi kepada pemegang keputusan/audiens
 - Data : descriptive, diagnostic, predictive, and prescriptive
 - Narasi : alur cerita yang digunakan untuk meyakinkan dan memberi masukan dan inspirasi
 - Visualisasi: graphic dan tabel , video dan gambar

Data storyteller : data-driven

- Descriptive: What happened?
 - Variasi, sentimen pada media sosial, statistik diskriptif
- Diagnostic: Why did this happen?
 - Hubungan sebab akibat, analisa regresi
- Predictive: What might happen in the future?
 - forecasting
- Prescriptive: What should we do next?
 - Menggunakan algoritma machine learning untuk sistem rekomendasi, pembuatan keputusan

Skill yang dibutuhkan

- Machine Learning : dasar untuk sains data
- Modelling : memilih algoritma dan model yang sesuai dengan masalah yang dipecahkan
- Statistics
- Programming : Python dan R
- Database : kemampuan untuk mengatur dan mendapatkan data dari sumber data

Komunitas Sains Data

- <https://linktr.ee/datascienceindo>
- <https://datascience.or.id>
- [https://web.facebook.com/datascienceindo?
rdc=1&rdr](https://web.facebook.com/datascienceindo?rdc=1&rdr)


Kurikulum Sains Data

- <https://dsi-data-curriculum.gitbook.io/ds-curriculum/>
- <https://pll.harvard.edu/subject/data-science>
- Mbah Google.com

Metodology Sains Data

- Waterfall
- KDD
- SEMMA
- **CRISP-DM**
- TSDP
- Domino
- Pendekatan lain

CRISP-DM



Hand, D., Mannila, H., Smyth, P., 2001. Principles of Data Mining. The MIT Press:
A Bradford Book, Cambridge, MA/London

Tahapan CRISP-DM

- Business Understanding
- Data understanding
- Data Preprocessing
- Modelling
- Evaluation
- Deployment

Bussiness Understanding

- **Menentukan Tujuan Bisnis**
- **Membuat Rencana Proyek**
- **Menilai situasi dan kondisi**

Data understanding

- Mengumpulkan data awal
- Mendiskripsikan data
- Ekplorasi data /Menyelidiki data
- Verifikasi kualitas data

Data preprocessing

- Integrasi data
- Memilih data (Select data)
- Membersihkan data (Clean data)
- Transformasi Data
- Rekayasa data

Modelling

- Pada tahapan ini membangun suatu model dari data yang diperoleh dari langkah sebelumnya untuk menjawab pertanyaan kebutuhan bisnis dengan berbagai macam metode. Beberapa metode yang dapat digunakan adalah metode statistik, pembelajaran mesin, riset operasi dan sebagainya.
- Dalam melakukan pemodelan data beberapa hal yang dilakukan adalah memilih variabel model, menjalankan model, dan mendiagnosa, optimasi model

Evaluation

- Evaluasi model adalah proses menggunakan ukuran evaluasi memahami kinerja model pembelajaran mesin, serta kekuatan dan kelemahannya.
 - Klasifikasi :
 - Akurasi
 - Recall
 - Precision
 - ROC
 - DII
 - Clustering:
 - Internal validation (Silhoeten coefisien)
 - External validation (Jika ada groudtruth)
 - Peramalan
 - MSE, RMSE, MAPE

Deployment

- Mengubah model dari eksperimen atau prototipe menjadi **solusi yang aktif dan dapat digunakan secara praktis.**
- Tujuan
 - Mewujudkan nilai bisnis dari model machine learning.
 - Memungkinkan pengguna (internal/eksternal) mengakses hasil prediksi secara real-time atau batch
 - Mengintegrasikan model ke dalam sistem operasional perusahaan (seperti CRM, ERP, aplikasi web, dll).
 - Memastikan model berjalan stabil, aman, dan dapat diskalakan

Kebutuhan Sain Data (Minggu depan dicek tool berikut: tidak install dikeluarkan dari kelas !

- Tools EDA : Power BI, Exploratory

Exploratory : <https://exploratory.io/>

Power BI : <https://www.microsoft.com/en-us/power-platform/products/power-bi/downloads>


Orange Data Mining :

<https://orangedatamining.com/download/>


Sudah mempunya web statis :

- Language : Python
- Jupyter Book : Reporting :
<https://jupyterbook.org/en/stable/intro.html>

Power BI




Orange




Exploratory

Click + button next to Data Frames
and import new data
or click existing Data Frames or Reports

Web Statis :



Ringkasan



Alhamdulillah